

PENGENALAN WAJAH MENGGUNAKAN *K-NEAREST NEIGHBOUR* DENGAN PRAPROSES TRANSFORMASI WAVELET

Muhammad Ilyas Sikki

ABSTRACT

Biometrics is the study of automated method to recognize or identify people based on one or more parts of the human body or the behavior of man himself. Facial image recognition is the process of matching between the characteristics of the image query image with the characteristics of the training image stored in a database (image library) that implement it through a mathematical transformation that is by using wavelet transform. The image is a spatial dimension that contains the color information and does not depend on the time consisted of a set of image dots, called pixels (picture element). K-NearestNeighbour(kNN) is a method that uses a supervised algorithm where the result of new instancequery classified based on kNN majority of categories that works based on the shortest distance from the query instance to the training sample to determine its kNN. The wavelet transform is used as a method of feature extraction as well as reduce the dimension of the input image with 3 levels of wavelet transform to generate multi-resolution representation. Decomposition of facial images using wavelet transform produces a number of subimage wich consists of image and detail images approach. The result of wavelet transform is used as input for classification. Classification system with a simple method of k-nearest neighbor (k-nn) to determine the identity of a face image with the threshold value of accuracy used in this study is 95%.

Keywords: *Biometrics, Image, Wavelet Transformation, Decomposition, kNN*

I. PENDAHULUAN

Biometrik merupakan studi tentang metode otomatis untuk mengenali atau mengidentifikasi manusia berdasarkan satu atau lebih bagian tubuh manusia atau kelakuan dari manusia itu sendiri. Dalam dunia teknologi informasi, biometrik relevan dengan teknologi yang digunakan untuk menganalisa fisik dan kelakuan manusia untuk autentifikasi. Salah satu contohnya dalam pengenalan fisik manusia yaitu dengan pengenalan pola dari wajah (*facial patterns*).

Pengenalan wajah adalah salah satu bidang penelitian penting dengan banyak aplikasi yang menerapkannya melalui transformasi matematis, karena wajah manusia merepresentasikan sesuatu yang kompleks sehingga untuk mengembangkan model komputasi yang ideal adalah sulit, karena setiap metode memiliki kelebihan dan kekurangan.

Trasformasi matematis digunakan terhadap suatu sinyal untuk mengetahui informasi lain yang terkandung dalam sinyal tersebut yang tidak dapat terbaca pada sinyal aslinya. Ada banyak metode yang digunakan untuk melakukan tranformasi. Dua diantaranya adalah Transfomasi Fourier dan Transformasi *Wavelet*. Dalam prakteknya kebanyakan sinyal berada dalam domain waktu, sehingga sinyal selalu dinyatakan dalam fungsi waktu. Dengan kata lain ketika menggambarkan grafik sinyal, hasilnya selalu dalam koordinat waktu dan amplitude. Representasi ini tidak selalu merupakan representasi terbaik untuk pemrosesan sinyal. Dalam beberapa kasus, informasi yang diperlukan

tersembunyi dalam frekuensi sinyal. Spektrum frekuensi suatu sinyal menunjukkan frekuensi apa saja yang ada dalam sinyal.

Metode *wavelet* merupakan suatu metode baru yang lebih efektif dari deret Fourier karena basis dalam *wavelet* ditentukan oleh letak dan skalanya sehingga mampu menangani masalah-masalah lokal yang tidak dapat dilakukan oleh Fourier. Salah satu aplikasi deret *wavelet* untuk menganalisa image, seperti analisa image wajah dan sidik jari dalam bidang kriminal, serta analisa magnetik resonansi (MR) *image brain* dalam bidang kedokteran.

Teknik pengenalan wajah dapat diaplikasikan dalam bidang forensik, penegakan hukum, dan lainnya. Aplikasi ini dapat diklasifikasikan secara luas kedalam dua kelompok, yaitu aplikasi dengan masukan gambar yang diam (contoh: kartu identitas, SIM, dan lain-lain) dan gambar bergerak atau dinamis. Pada gambar diam gambar yang diambil hanya pada gambar tampak depan dengan berbagai ekspresi wajah, misalnya: senyum, tertawa, melotot, berkacamata dan lain-lain. Dengan majunya zaman maka wajah yang diambil bukan hanya wajah diam dari depan, tetapi mulai dengan gambar banyak arah yaitu dengan berbagai macam ekspresi baik menoleh ke kanan atau ke kiri, tidak hanya tampak depan saja.

Secara umum sistem pengenalan citrawajah dibagi menjadi 2 jenis yaitu: sistem *feature-based* dan sistem *image-based*. Pada sistem pertama digunakan fitur yang diekstraksi dari komponen citra wajah (mata, hidung, mulut, dll) yang kemudian dimodelkan secara geometris hubungan antara fitur-fitur tersebut. Sedangkan pada sistem ke dua menggunakan informasi mentah dari pixel citra yang kemudian direpresentasikan dalam metode tertentu (misalnya *Principal Component Analysis (PCA)*, transformasi *wavelet*, dll) yang kemudian digunakan untuk pelatihan dan klasifikasi identitas citra. Dekomposisi citra wajah menggunakan transformasi *wavelet* menghasilkan sejumlah sub-citra yang terdiri dari citra pendekatan dan citra detil. Hasil transformasi *wavelet* ini digunakan sebagai input untuk klasifikasi dengan metode sederhana *k-nearest neighbour (k-nn)*. Penelitian ini bertujuan mempelajari, memahami dan mengimplementasikan pengenalan wajah dengan menggunakan *k-nearest neighbour (k-nn)* dengan pra-proses transformasi *Wavelet*.

II. TINJAUAN PUSTAKA

2.1. Citra

Definisi citra menurut kamus Webster adalah suatu representasi, kemiripan, atau imitasi dari suatu obyek atau benda. Sebuah citra mengandung informasi tentang obyek yang direpresentasikan. Citra dapat dikelompokkan menjadi citra tampak dan citra tak tampak. Untuk dapat dilihat mata manusia, citra tak tampak harus diubah menjadi citra tampak, misalnya dengan menampilkannya di monitor, dicetak di kertas dan sebagainya. Salah satu contoh citra tak tampak adalah citra digital. Citra dapat juga didefinisikan sebagai gambar dua dimensi yang dihasilkan dari gambar analog dua dimensi yang kontinu menjadi gambar diskrit melalui proses *sampling*. Gambar analog dibagi menjadi N baris dan M kolom sehingga menjadi gambar diskrit. Persilangan antara baris dan kolom tertentu

disebut dengan *piksel*. Contohnya adalah gambar/titik diskrit pada baris n dan kolom m disebut dengan $\text{piksel}[n,m]$. Sampling adalah proses untuk menentukan warna pada piksel tertentu pada citra dari sebuah gambar yang kontinu. Pada proses sampling biasanya dicari warna rata-rata dari gambar analog yang kemudian dibulatkan kedalam angka bulat. Proses sampling sering juga disebut proses digitisasi. Ada kalanya, dalam proses sampling, warna rata-rata yang didapat di relasikan ke level warna tertentu. Contohnya apabila dalam citra hanya terdapat 16 level warna abu-abu, maka nilai rata-rata yang didapat dalam proses sampling harus diasosiasikan ke 16 level tersebut. Proses mengasosiasikan warna rata-rata dengan level warna tertentu disebut dengan kuantisasi.

Citra merupakan dimensi spasial yang berisi informasi warna dan tidak bergantung pada waktu. Citra merupakan sekumpulan titik-titik dari gambar, yang disebut *pixel* (*picture element*). Titik-titik tersebut menggambarkan posisi koordinat dan mempunyai intensitas yang dapat dinyatakan dengan bilangan. Intensitas ini menunjukkan warna citra, melalui penjumlahan (*Red, Green dan Blue / RGB*). Koordinat memberikan informasi warna pixel berdasarkan; *Brightness* (ketajaman) warna cahaya (hitam, abu-abu, putih) dari sumber, *Hue* (corak warna) yang ditimbulkan oleh warna (merah, kuning, hijau dll) dan merupakan panjang gelombang dominan dari sumber.

Pemrosesan citra melibatkan perubahan sifat dari citra yang bertujuan agar citra menjadi baik dengan cara :

1. Meningkatkan informasi bergambar pada interpretasi manusia, mencakup :
 - Meningkatkan *edge* dari citra untuk membuat tampak lebih tajam, sebagai contoh, pada gambar 1 berikut terlihat pada image kedua tampak lebih bersih dan lebih nyaman. Menajamkan *edge* adalah salah satu komponen yang penting pada pengeprintan, dengan tujuan supaya citra tampak baik pada halaman yang diprint, beberapa penajaman biasanya ditampilkan.



Gambar 1. Penajaman citra (KiriCitra asli, kanan Hasil setelah penajaman)

- Menghapus *noise* dari sebuah citra, *noise* akan menjadi eror acak dalam citra. Sebagai contoh diberikan pada gambar 2. *Noise* adalah masalah yang sangat umum dalam transmisi data, semua jenis komponen elektronik mungkin dapat mempengaruhi data yang melewati diantaranya dan hasilnya tidak diinginkan.



Gambar 2 . Menghilangkan *Noise* Pada Citra(Kiri Citra asli, kanan Setelah dihilangkan noise)

- Menghapus *motion blur* dari sebuah citra, terlihat pada contoh gambar 3. *Deblurred* citra terlihat pada gambar(b), lebih mudah untuk membaca numberplate dan untuk melihat spike pada fence disamping mobil sama baiknya dengan bagian lain tanpa jelas pada gambar asal (a). *motion*


blur mungkin terjadi ketika alat pengatur kecepatan cahaya pada kamera terlalu panjang untuk kecepatan pada benda. Pada fotografi pada benda yang berpindah cepat, seperti atlet, dan kendaraan. Sebagai contoh, masalah kabur mungkin akan sangat dipertimbangkan.



Gambar 3. Image *Deblurring*(KiriCitra Asli, kanan Setelah Dihilangkan *Blur*)

2. Membuat kecocokan pada mesin persepsi otonom

Perolehan *edges* dari sebuah citra, hal ini mungkin dibutuhkan pada pengukuran benda dalam sebuah citra. Sebagai contoh pada gambar 4, dapat dilakukan pengukuran penyebaran dan area yang terdapat didalamnya. Algoritma pencarian edge dapat digunakan sebagai langkah awal *edge enhancement*.



Gambar 4. Menemukan Edges Dalam Citra(KiriGambar asli, kanan setelah dihilangkan *blur*)

Pada konsep pengolahan citra, harus mengubah suatu citra dari satu domain ke domain lainnya. Perubahan ini bertujuan untuk mempermudah pengkodean. Proses perubahan ini dinamakan transformasi. Transformasi citra dapat menghasilkan energi citra yang terkonsentrasi pada sebagian kecil koefisien transformasi dan kelompok lain yang mengandung sedikit energi. Transformasi ini dapat dilakukan dengan beberapa metode antara lain adalah discrete cosines transform, discrete fourier transformasi, transformasi *wavelet*. Keuntungan penggunaan transformasi adalah hasil dari domain lebih sesuai untuk proses pengkuantisasian.

Transformasi Fourier merupakan representasi dari sebuah citra sebagai penjumlahan eksponensial kompleks dari beragam magnitude, frekuensi dan fasa. Transformasi Fourier akan menghasilkan Fourier Spectrum. Fourier Spektrum dapat memberikan informasi tentang tinggi rendah frekuensi citra. Jika ingin melakukan filtering terhadap citra pada domain frekuensi Fourier, maka dapat menggunakan lowpass filtering maupun highpass filtering. Tujuan transformasi Fourier adalah mengetahui frekuensi citra, bukan untuk kompresi, sehingga hasil transformasi fourier tidak akan mendukung kompresi (tidak bersifat compact support). Transformasi yang cocok untuk kompresi adalah transformasi *wavelet*. Hal ini dikarenakan jika melakukan kompresi pada bagian detail, citra invers atau citra hasil rekonstruksi tidak akan terlalu berbeda dengan citra awal. Transformasi *wavelet* mendekomposisi sinyal dalam komponen frekuensinya dengan tetap mempertahankan informasi koordinat spasial dari komponen frekuensi tersebut.

2.2. Wavelet

Wavelet merupakan kelas dari suatu fungsi yang digunakan untuk melokalisasi suatu fungsi dalam ruang dan skala. Wavelet merupakan gelombang mini (*small wave*) yang mempunyai kemampuan mengelompokkan energi citra terkonsentrasi pada sekelompok kecil koefisien, sedangkan kelompok koefisien lainnya hanya mengandung sedikit energi yang dapat dihilangkan tanpa mengurangi nilai informasinya. Wavelet dapat dibentuk dari satu fungsi $\Psi(x)$, dikenal sebagai “mother wavelet” dalam suatu interval berhingga. “Daughter wavelet” $\Psi_{a,b}(x)$ dibentuk oleh translasi (b) dan kontraksi (a). Wavelet sangat berguna untuk kompresi data image, karena transformasi wavelet mempunyai property yang ada dalam beberapa cara transformasi Fourier konvensional. Wavelet tunggal dapat didefinisikan dengan :

$$\Psi_{a,b}(x) = \frac{1}{\sqrt{a}} \Psi\left(\frac{x-b}{a}\right)$$

dimana a = parameter skala

b = parameter translasi

$\frac{1}{\sqrt{a}}$ = normalisasi energi yang sama dengan energi induk.

Selanjutnya :

$$W_{\Psi}(f)(a,b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{\infty} f(t) \Psi\left(\frac{t-b}{a}\right) dt$$

dan formula Calderon memberikan :


$$f(x) = C_{\Psi} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \langle f, \Psi^{a,b} \rangle \Psi^{a,b}(x) a^{-2} da db$$

Wavelet yang sering digunakan didefinisikan dengan fungsi Haar sebagai berikut:

$$\Psi(x) = \begin{cases} 1 & 0 \leq x \leq \frac{1}{2} \\ -1 & \frac{1}{2} < x \leq 1 \\ 0 & \text{otherwise} \end{cases}$$

dan $\Psi_{jk}(x) = \Psi(2^j x - k)$ dengan j integer dan nonnegative, $0 \leq k \leq 2^j - 1$.


Transformasi wavelet memberikan informasi tentang kombinasi *skala dan frekuensi*, sehingga terhadap suatu sinyal yang kita punyai maka hasil dari Transformasi Waveletnya akan mempunyai tiga koordinat yakni amplitudo, translasi dan skala seperti pada gambar berikut.



Gambar 5. Suatu sinyal berikut transformasi waveletnya
(Kiri Sinyal asli, kanan Transformasi waveletnya)

Transformasi *wavelet* merupakan alat yang dapat digunakan untuk menyajikan data ke dalam komponen-komponen frekuensi dan setiap komponen frekuensi dapat dikaji melalui suatu resolusi yang sesuai dengan skalanya. Transformasi *wavelet* banyak digunakan untuk analisis dan

representasi isyarat/signal, karena sederhana dan mudah diimplementasikan. Proses transformasi dapat dilakukan dengan konvolusi atau dengan proses perata-rataan dan pengurangan secara berulang, yang sering disebut dengan metode *filter bank*. Gambar berikut menyajikan proses transformasi *wavelet* dengan cara *filter bank*.



Gambar 6. Transformasi *wavelet* secara *filter bank*.

dengan

$$c^j = [c_0^j \dots c_{2^j-1}^j]$$

merupakan nilai-nilai koefisien (dalam citra, merupakan nilai warna titik) yang berupa matriks kolom. c^{j-1} dan d^{j-1} dihitung melalui persamaan :


$$c^{j-1} = A^j c^j$$

$$d^{j-1} = B^j c^j$$

Untuk basis Haar yang tidak ternormalisasi :

$$A^2 = \frac{1}{2} \begin{bmatrix} 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \end{bmatrix}; B^2 = \frac{1}{2} \begin{bmatrix} 1 & -1 & 0 & 0 \\ 0 & 0 & 1 & -1 \end{bmatrix}$$

Matriks A dan B di atas merepresentasikan operasi perata-rataan dan pengurangan. Berdasarkan atas dimensi sinyal yang ditransformasikan, transformasi *wavelet* dapat dikelompokkan menjadi dua, yaitu aliragam *wavelet* satu-dimensi dan aliragam *wavelet* dua-dimensi. Transformasi *wavelet* dua-dimensi merupakan pengeneralisasian transformasi *wavelet* satu-dimensi. Langkah-langkah transformasi *wavelet* dua-dimensi dapat diilustrasikan pada Gambar berikut.



Gambar 7. Algoritma transformasi *wavelet* diskret dua-dimensi


dimana :

- $\begin{bmatrix} 2 & 1 \end{bmatrix}$ merupakan downsample kolom
- $\begin{bmatrix} 1 & 2 \end{bmatrix}$ merupakan downsample baris

Seperti yang terlihat pada Gambar diatas, jika suatu citra dilakukan proses transformasi wavelet diskrit dua dimensi dengan level dekomposisi satu, maka akan menghasilkan empat buah *subband*, yaitu :

1. Koefisien Aproksimasi (CA_{j+1}) atau disebut juga *subband* LL
2. Koefisien Detil Horisontal ($CD(h)_{j+1}$) atau disebut juga *subband* HL

3. Koefisien Detil Vertikal ($CD(v)_{j+1}$) atau disebut juga *subband* LH
4. Koefisien Detil Diagonal ($CD(d)_{j+1}$) atau disebut juga *subband* HH




LL	LH	LL : hasil lowpass terhadap baris dan kolom
		LH : hasil lowpass terhadap baris diteruskan dengan highpass terhadap kolom
HL	HH	HL : hasil highpass terhadap baris diteruskan dengan lowpass terhadap kolom
		HH : hasil highpass terhadap baris dan kolom

Dari Level Dekomposisi 1 *Subband* hasil dari dekomposisi dapat didekomposisi lagi karena level dekomposisi wavelet bernilai dari 1 sampai n atau disebut juga transformasi wavelet multilevel. Jika dilakukan dekomposisi lagi, maka *subband* LL yang akan didekomposisi karena *subband* LL berisi sebagian besar dari informasi citra. Jika dilakukan dekomposisi dengan level dekomposisi dua maka *subband* LL akan menghasilkan empat buah *subband* baru, yaitu *subband* LL2 (Koefisien Aproksimasi 2), HL2 (Koefisien Detil Horisontal 2), LH2 (Koefisien Detil Vertikal 2), dan HH2 (Koefisien Detil Diagonal 2). Dan begitu juga seterusnya jika dilakukan dekomposisi lagi.

LL2	LH2	LH1	LH1, HL1, dan HH1 merupakan hasil dekomposisi level 1.
HL2	HH2		
HL1		HH1	LL1 tidak diperlihatkan pada gambar karena langsung didekomposisi lagi menjadi LL2, LH2, HL2 dan HH2


Pada gambar berikut ditunjukkan citra *approximation* dan citra *details* yang diasumsikan merupakan hasil divided dari citra asli, citra-citra tersebut dapat di dekomposisikan kembali secara bertingkat dengan level ke n .



Gambar 8. Dekomposisi Wavelet

Wavelet induk *diskalakan* dan *ditranslasikan* melalui pemisahan menurut frekwensi menjadi sub-sub bagian. Untuk mendapatkan sinyal kembali dilakukan rekontruksi wavelet. Misalkan suatu citra

dibagi menjadi komponen frekwensi rendah dan fekwensi tinggi dengan menggunakan filter *Daubechies*. Gambar berikut memperlihatkan proses pemisahan frekuensi kemudian direkonstruksikan kembali.




Gambar 9. Blok Diagram Pemisahan Frekwensi

Dimana : G = filter tapis bawah (low)

H = filter tapis atas (high)

Sub-band = desimilasi dan interpolasi



Gambar 10. Blok Diagram Rekontruksi Frekwensi

2.3. K-Nearest Neighbor

K-Nearest Neighbor (KNN) adalah suatu metode yang menggunakan algoritma *supervised* dimana hasil dari *query instance* yang baru diklasifikan berdasarkan mayoritas dari kategori pada KNN. Tujuan dari algoritma ini adalah mengklasifikasikan obyek baru berdasarkan atribut dan *training sample*. *Classifier* tidak menggunakan model apapun untuk dicocokkan dan hanya berdasarkan pada memori. Diberikan titik *query*, akan ditemukan sejumlah k obyek atau (titik *training*) yang paling dekat dengan titik *query*. Klasifikasi menggunakan *voting* terbanyak diantara klasifikasi dari k obyek. Algoritma KNN menggunakan klasifikasi ketetanggaan sebagai nilai prediksi dari *query instance* yang baru.

Algoritma metode KNN sangatlah sederhana, bekerja berdasarkan jarak terpendek dari *query instance* ke *training sample* untuk menentukan KNN-nya. *Training sample* diproyeksikan ke ruang berdimensi banyak, dimana masing-masing dimensi merepresentasikan fitur dari data. Ruang ini dibagi menjadi bagian-bagian berdasarkan klasifikasi *training sample*. Sebuah titik pada ruang ini ditandai kelas c jika kelas c merupakan klasifikasi yang paling banyak ditemui pada k buah tetangga terdekat dari titik tersebut. Dekat atau jauhnya tetangga biasanya dihitung berdasarkan *Euclidean Distance* yang direpresentasikan sebagai berikut :


$$D(a, b) = \sqrt{\sum_{k=1}^d (a_k - b_k)^2},$$

dimana matriks $D(a,b)$ adalah jarak skalar dari kedua vektor a dan b dari matriks dengan ukuran d dimensi.


Pada fase *training*, algoritma ini hanya melakukan penyimpanan vektor-vektor fitur dan klasifikasi data *training sample*. Pada fase klasifikasi, fitur-fitur yang sama dihitung untuk *testing*

data (yang klasifikasinya tidak diketahui). Jarak dari vektor baru yang ini terhadap seluruh vektor *training sample* dihitung dan sejumlah k buah yang paling dekat diambil. Titik yang baru klasifikasinya diprediksikan termasuk pada klasifikasi terbanyak dari titik-titik tersebut.

Sebagai contoh, untuk mengestimasi $p(x)$ dari n *training sample* dapat memusatkan pada sebuah sel disekitar x dan membiarkannya tumbuh hingga meliputi k *samples*. *Samples* tersebut adalah KNN dari x . Jika densitasnya tinggi di dekat x , maka sel akan berukuran relatif kecil yang berarti memiliki resolusi yang baik. Jika densitas rendah, sel akan tumbuh lebih besar, tetapi akan berhenti setelah memasuki wilayah yang memiliki densitas tinggi. Pada gambar berikut ditampilkan estimasi densitas satu dimensi dan dua dimensi dengan KNN.




Gambar 11. Delapan titik dalam satu dimensi dan estimasi densitas KNN dengan $k = 3$ dan $k = 5$



Gambar 12. KNN mengestimasi densitas dua dimensi dengan $k = 5$

Nilai k yang terbaik untuk algoritma ini tergantung pada data. Secara umum, nilai k yang tinggi akan mengurangi efek *noise* pada klasifikasi, tetapi membuat batasan antara setiap klasifikasi menjadi semakin kabur. Nilai k yang bagus dapat dipilih dengan optimasi parameter, misalnya dengan menggunakan *cross-validation*. Kasus khusus dimana klasifikasi diprediksikan berdasarkan *training data* yang paling dekat (dengan kata lain, $k = 1$) disebut algoritma *nearest neighbor*.

Pada gambar 13 memperlihatkan pola geometri dari knn. Hal yang dibutuhkan, memilih k jumlah tetangga paling dekat pada daerah sembarang yang tidak dilabel vektor Z dalam R^P dan beberapa pengukuran panjang antara pasangan vektor dalam R^P biasanya panjang Euclidean. Metric δ mendefenisikan bentuk dari daerah pada k tetangga paling dekat pada z . Pada kasus ini k diambil sebagai *integer* ganjil menghindari lintasan dalam $c=2$ pada *class case*. Data yang dilabel terlihat pada gambar 13, yang terdiri atas 11 objek masing-masing mempunyai $c=3$ *crisp* label, diperlihatkan pada bagian atas gambar. Dengan norm Euclidean dan $k=6$ tetangga terdekat mempunyai $c=3$ label kelas, titik z akan dilabel sebagai kelas 2 titik karena 3 dari 6 tetangga Euclidean.

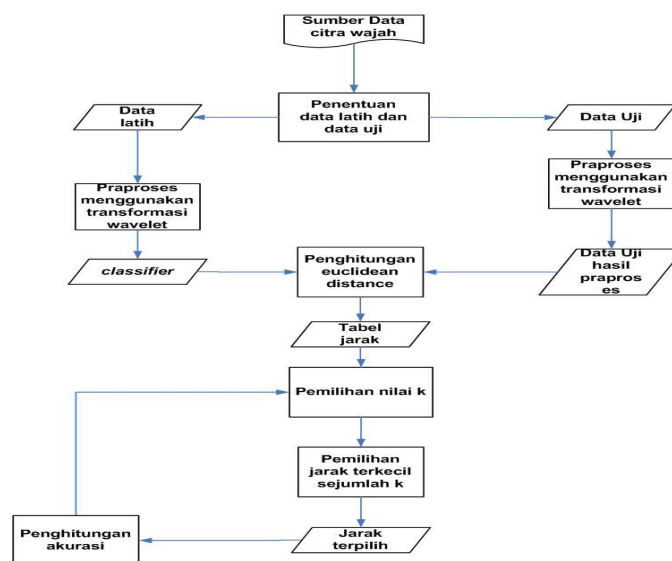
Gambar 13. Gambaran geometric dari *crispknn* aturan klasifikasi

Ketepatan algoritma KNN sangat dipengaruhi oleh ada atau tidaknya fitur-fitur yang tidak relevan atau jika bobot fitur tersebut tidak setara dengan relevansinya terhadap klasifikasi. Riset terhadap algoritma ini sebagian besar membahas bagaimana memilih dan memberi bobot terhadap fitur agar performa klasifikasi menjadi lebih baik.

KNN memiliki beberapa kelebihan yaitu ketangguhan terhadap *training data* yang memiliki banyak *noise* dan efektif apabila *training data*-nya besar. Sedangkan, kelemahan KNN adalah KNN perlu menentukan nilai dari parameter k (jumlah dari tetangga terdekat), *training* berdasarkan jarak tidak jelas mengenai jenis jarak apa yang harus digunakan dan atribut mana yang harus digunakan untuk mendapatkan hasil terbaik, dan biaya komputasi cukup tinggi karena diperlukan perhitungan jarak dari tiap *query instance* pada keseluruhan *training sample*.

III. METODOLOGI

Penelitian ini merupakan implementasi dari pengetahuan tentang transformasi wavelet untuk praproses citra wajah yang selanjutnya di klasifikasikan dengan menggunakan metode *k-nearest neighbor* (*k-nn*) untuk menentukan citra wajah dari databasenya. Data yang digunakan dalam percobaan ini adalah 80 citra wajah yang terdiri dari 8 individu dengan masing-masing 10 wajah per individu. Citra wajah memiliki beberapa variasi seperti tersenyum, menggunakan kacamata atau tidak, dan mata terbuka atau tertutup. Percobaan ini dilakukan secara bertahap sesuai tahapan yang telah disusun pada Gambar berikut.



Gambar 14. Diagram Alir Metode Penelitian

Nilai *threshold* akurasi yang digunakan pada penelitian ini adalah 95%. Citra wajah dibagi menjadi 2 kelompok yaitu data latih dan data uji, data latih terdiri dari 64 foto (8 citra berbeda dari setiap individu) dan data uji terdiri dari 16 foto (2 citra berbeda dari setiap individu). Sehingga citra yang digunakan sebagai data uji adalah citra yang sebelumnya belum dikenali oleh sistem. Dekomposisi wavelet dengan menggunakan haar. Dekomposisi dilakukan sampai level 4. Nilai k yang digunakan antara 4 sampai 8.

IV. HASIL DAN PEMBAHASAN

Data citra wajah yang digunakan pada percobaan ini terdapat pada gambar berikut :



Gambar 15. Citra untuk Pengujian

Klasifikasi dengan menggunakan citra hasil praproses transformasi wavelet dekomposisi level 4, menggunakan nilai $k = 4, 5, 6, 7, 8$. Hasil yang diperoleh dapat dilihat pada Tabel 1.

Tabel 1. Hasil dekomposisi level 4

K	banyaknya citra uji yang benar diklasifikasikan	jumlah total citra uji	Akurasi
4	16	16	100%
5	16	16	100%
6	16	16	100%
7	14	16	87.5%
8	14	16	87.5%

Untuk klasifikasi menggunakan hasil praproses transformasi wavelet dekomposisi level 3, juga digunakan nilai $k = 4, 5, 6, 7, 8$. Hasil yang diperoleh dari hasil klasifikasi dapat dilihat pada Tabel 2.

Tabel 2. Hasil dekomposisi level 3

K	banyaknya citra uji yang benar diklasifikasikan	jumlah total citra uji	Akurasi
4	16	16	100%
5	16	16	100%
6	16	16	100%
7	14	16	87.5%
8	14	16	87.5%

Klasifikasi menggunakan hasil praproses transformasi wavelet dekomposisi level 2, dengan menggunakan nilai $k = 4,5,6,7,8$. Hasil yang diperoleh dari hasil klasifikasi dapat dilihat pada Tabel 3.

Tabel 3. Hasil dekomposisi level 2

K	banyaknya citra uji yang benar diklasifikasikan	jumlah total citra uji	Akurasi
4	16	16	100%
5	16	16	100%
6	16	16	100%
7	15	16	93.75%
8	15	16	93.75%

Untuk klasifikasi menggunakan hasil praproses transformasi wavelet dekomposisi level 3, juga digunakan nilai $k = 4,5,6,7,8$. Hasil yang diperoleh dari hasil klasifikasi dapat dilihat pada Tabel 4.

Tabel 4. Hasil dekomposisi level 1

K	banyaknya citra uji yang benar diklasifikasikan	jumlah total citra uji	Akurasi
4	16	16	100%
5	16	16	100%
6	16	16	100%
7	15	16	93.75%
8	16	16	100%

Dari keempat tabel hasil di atas, dapat diperoleh hasil yang memenuhi nilai threshold, yaitu 95%. Kombinasi level dekomposisi dan nilai k yang memenuhi nilai threshold adalah :

- | | |
|------------------------------------------|------------------------------------------|
| a. Dekomposisi level 4
dengan $k = 4$ | h. Dekomposisi level 2
dengan $k = 5$ |
| b. Dekomposisi level 4
dengan $k = 5$ | i. Dekomposisi level 2
dengan $k = 6$ |
| c. Dekomposisi level 4
dengan $k = 6$ | j. Dekomposisi level 1
dengan $k = 4$ |
| d. Dekomposisi level 3
dengan $k = 4$ | k. Dekomposisi level 1
dengan $k = 5$ |
| e. Dekomposisi level 3
dengan $k = 5$ | l. Dekomposisi level 1
dengan $k = 6$ |
| f. Dekomposisi level 3
dengan $k = 6$ | m. Dekomposisi level 1
dengan $k = 8$ |
| g. Dekomposisi level 2
dengan $k = 4$ | |

Dari hasil di atas, dapat dilihat bahwa penambahan informasi input yang terjadi dari dekomposisi level 4 menjadi level 3, tidak memberikan peningkatan akurasi. Nilai akurasi yang diperoleh dari dekomposisi level 3 dengan $k = 4, 5, 6, 7, 8$ sama dengan dekomposisi level 4 dengan $k = 4, 5, 6, 7, 8$. Sedangkan untuk penambahan informasi input yang terjadi dari dekomposisi level 3 menjadi level 2, terlihat bahwa terjadi peningkatan akurasi pada $k=7$ dan $k=8$. Dimana akurasi dekomposisi level 3 dengan $k= 7$ adalah 87.5% dan akurasi dekomposisi level 2 dengan $k= 7$ adalah 93.75% . Akurasi dekomposisi level 3 dengan $k= 8$ adalah 87.5% dan akurasi dekomposisi level 2 dengan $k= 8$ adalah 93.75%. Untuk penambahan informasi input yang terjadi dari dekomposisi level 2 menjadi level 1, juga terjadi peningkatan akurasi. Peningkatan akurasi terjadi pada $k = 8$. Dimana akurasi dekomposisi level 2 dengan $k= 8$ adalah 93.75% dan akurasi dekomposisi level 1 dengan $k= 8$ adalah 100%.

V. KESIMPULAN

Kesimpulan yang dapat ditarik dari Penelitian ini adalah sebagai berikut :

1. Transformasi merupakan suatu langkah yang harus dilakukan untuk mengubah penyajian suatu sinyal dari suatu domain ke domain yang lain.
2. Citra merupakan gambar dua dimensi yang dihasilkan dari gambar analog dua dimensi yang kontinu menjadi gambar diskrit melalui proses sampling yang dapat direpresentasikan dalam elemen-elemen array suatu matriks.
3. Konsep pengolahan citra dalam mengubah suatu citra dari satu domain ke domain lainnya dengan tujuan untuk mempermudah pengkodean menggunakan transformasi wavelet.
4. Transformasi *wavelet* merupakan alat yang dapat digunakan untuk menyajikan data kedalam komponen-komponen frekuensi dan setiap komponen frekuensi dapat dikaji melalui suatu resolusi yang sesuai dengan skalanya.
5. Level dekomposisi suatu citra dalam transformasi wavelet dapat diturunkan dari koefisien aproksimasi sub-band dari level 1 sampai n .
6. *K-Nearest Neighbor* (KNN) merupakan metode pengklasifikasian data untuk mencari jarak terdekat antara data yang akan dievaluasi dengan K tetangga terdekatnya dalam data pelatihan.
7. Dekomposisi wavelet dilakukan sampai dengan level 4.
8. Nilai k yang digunakan adalah 4,5,6,7,8. Dengan nilai k yang memberikan akurasi diatas 95% adalah $k = 4,5,6$ untuk dekomposisi level 4, level 3, dan level 2. Sedangkan untuk dekomposisi level 1, nilai k yang memberikan akurasi di atas 95% adalah $k = 4,5,6,8$.

DAFTAR PUSTAKA

- [1] Alasdair McAndrew, An Introduction to Digital Image Processing with Matlab. McAndrew, A., 2004, *An Introduction to Digital Image Processing with Matlab*, notes for SCM2511 Image.
- [2] Paul Wintz, 2000, *Digital Image Processing*, Prentice-Hall.
- [3] Bezdek, C.Dubois., Keller, J., Krisnapuram, R., Pal, N.R, 2005, Fuzzy Models and Algorithms for Pattern Recognition and Image Processing.
- [4] A. Rizal, V. Suryani, Pengenalan Suara Jantung Menggunakan Dekomposisi Paket Wavelet dan Jaringan Syaraf Tiruan ART2, Proceeding EECCIS 2006, Universitas Brawijaya, Malang , 2006
- [5] Suta Wijaya, Gede Pasek, Kanata, Bulkis, *Pengenalan Citra Sidik Jari Berbasis Transformasi Wavelet Jaringan Syaraf Tiruan*, Jurnal Teknik Elektro, Vol 4, No 1, 2004, pp, 46-52
- [6] Misiti, M., Misiti, Y., Oppenheim, G., Poggi, JM., *Wavelet Toolbox For Use with MATLAB*, The Math Works, Inc, 1997.